

An Item-Level Evidence-Based Framework for Evaluating Korean Language Capabilities in AI Models

“문제 묶음”이 아니라 “측정 가능한 증거 시스템”으로 보는 한국어 AI 성능 평가



2026.6.
(주)나라지식정보

1. 왜 지금 한국어 AI 평가를 다시 설계해야 하나?

AI의 한국어 성능은 "한국어로 답한다"가 아니라 "한국어 조건을 안정적으로 처리한다"이다.

기존 평가의 편의

대량 문항 풀이
평균 점수 산출
모델 순위 산정
리더보드 공유

한국어 평가의 난점

경어법, 높임, 공손성
담화 생략과 화시
문체와 레지스터
방언, 고어, 신조어

필요한 전환

문항별 구인을 기록
난이도 근거를 저장
모델 응답 로그 보존
문항 수명주기 운영

평가의 목표는 "점수 산출"이 아니라 "성능 해석의 근거 만들기"

2. 총점 중심 평가는 무엇을 숨기는가?

총점은 편리하지만, 능력 구조와 실패 원인을 거의 설명하지 못한다.

모델 A: 85점



모델 B: 82점



겉으로 보이는 것

```
aggregate_score(model) = correct / total
```

숨겨지는 것

어떤 구인을 측정했는가?

어떤 문항이 변별력이 있는가?

문항이 어려운가, 애매한가?

벤치마크가 이미 포화되었는가?

이 점수를 배포 판단에 써도 되는가?


총점은 요약값

문항 단위 증거는 설명값

운영 판단의 근거

3. 문항은 “문제”가 아니라 “증거 객체”다

문항 하나가 평가 시스템의 최소 실행 단위



```
ItemEvidence_i = {  
  content, construct, difficulty,  
  answer_key, rubric, response,  
  score, rationale, lifecycle_status  
}
```

문항 원문, 정답과 해설, 평가 요소와 난이도, 모델 응답, 채점 근거를 하나의 ItemEvidence 객체로 저장해야 나중에 “왜 이 모델이 실패했는지” 추적 가능

검증 가능성


재현성

오류 진단

문항 교체와 수명주기 관리

4. 학술적 계보: “그럴듯한 아이디어”가 아니라 이미 형성되고 있는 흐름

HELM, 측정 이론, 심리측정학, 문항반응이론, 문항 단위 데이터 공개 등 관련 논문 출판으로 학술적 흐름 형성



핵심 전환

aggregate score → item-level evidence → measurement science

5. 한국어 AI 능력은 어떤 구인으로 볼 것인가?

- 3개 상위 영역은 의사 소통 능력을 기준으로 언어 능력의 보편적 범주를 반영
- 14개 세부 영역은 한국어 AI 평가 목적에 맞춰 구체화한 운영형 평가 영역


의사소통 능력		도메인
문법적 능력	어휘, 형태, 통사, 의미, 음운 등의 언어 지식과 관련한 능력	맞춤법·띄어쓰기
		유익어
		고어
		문장성분 호응
담화적 능력	발화 상황 속에서 형태적인 결속구조(cohesion)와 의미적인 결속성(coherence)을 갖춘 담화를 구성하는 것과 관련한 능력	담화 연결·접속 표현
		문맥 이해도(화시)
		추론
		무형대용어 복원
사회언어학적 능력	담화가 이루어지는 사회언어학적인 상황을 제대로 파악하고 거기에 맞는 언어를 사용하는 것과 관련한 능력	경어법
		문체/레지스터 전환
		대화 화행·공손 전략
		관용표현
		방언
		신조어

※ 공통 평가 제약, 응답 산출 조건

형식 조건, 분량 조건, 구조화 응답, 필수 정보 포함, 금지어 준수, 환각 억제

6. Data–Information–Evidence–Action 파이프라인

데이터는 아직 근거가 아니다. 근거는 “주장을 정당화하는 정보”



예시

문항 원문, 정답, 해설, 모델
응답

추론 단계, 문항 명료도, 평균
정답률

DDI, EADI, DAE, IDQ, CDI

L1-L3 확정, 수정, 보류, 폐기

Data ≠ Evidence

Evidence = information used to justify a claim

7. Data 단계: 무엇을 반드시 저장해야 하는가?

문항과 응답을 나중에 검증 가능해야 함

문항 내용

지문, 발문, 선택지, 정답

해설·루브릭

정답 근거, 허용 답안, 감점 기준

실행 로그

모델명, 모델 버전, 프롬프트, 파라미터

응답·채점

모델 원응답, 점수, 채점 근거

출처·상태

문항 출처, 버전, 오염 위험, 수명주기

나중에 “왜 이 점수가 나왔는가?”를 추적할 수 없으면 운영형 evidence가 아니다.

8. Information 단계: 자동 설계난이도 벡터

문항 원자료를 읽고, 난이도에 영향을 주는 요소를 구조화

$$D_i^{\text{auto}} = (R_i, C_i, K_i, P_i, E_i, O_i, X_i, D_i^{\text{dist}}, M_i, Q_i)$$

R

Reasoning

추론 단계 수

C

Context

맥락 의존도

K

Korean-specificity

한국어 특성 부하량

P

Pragmatics

화용·사회언어학 부하량

E

External knowledge

외부 지식·문화 맥락

O

Openness

응답 개방성

X

Constraint complexity

제약 조건 복잡도

D_{ist}

Distractor plausibility

오답 매력도

M

Multi-construct integration

다중 구인 결합도

Q

Question clarity

문항 명료도

자동 난이도 평정은,
최종 난이도 라벨을 단번에 산출하지 않고,
추론 단계, 맥락 의존도, 한국어 특성, 화용 부담,
제약 조건, 문항 명료도 등을 분해 평가한 뒤
종합하여 실행




실제 적용 사례
(세부 내용 16항 참조)

하위 요인	체크 포인트
추론 단계 수	문제 표현 진단 → 수정 원칙 설정 → 이메일 수정 → 수정 이유 설명
맥락 의존도	외부 자문위원, 내부 결재, 중간보고 일정
한국어 특성 부하량	경어법, 격식체, 구어체와 문어체 차이
화용 부담	압박하지 않으면서 검토 요청하기
제약 조건 복잡도	수정 이메일 전문, 수정 이유 5문장, 150자 이내
문항 명료도	무엇을 고쳐야 하는지 기준이 분명한가

9. Evidence 단계: 난이도 판단은 여러 근거를 함께 보정한다

설계상 난이도, 실제 모델 반응, 문항 품질, 운영 위험을 함께 보아 L1, L2, L3 라벨을 판단

최종 난이도 판단은 단일 점수가 아니라, 설계 근거, 실제 응답 근거, 문항 품질 근거, 운영 위험 근거를 종합해 보정



종합 보정 결과

CDI (Calibrated Difficulty Index, 보정 난이도 지수) → L1, L2, L3 운영 라벨 → 채택, 수정, 보류, 폐기 판단

10. Action 단계: 증거는 실제 운영 결정으로 이어져야 한다

평가가 끝나는 지점은 점수표가 아니라 문항 상태와 모델 활용 판단

L1/L2/L3 확정

난이도 라벨 부여

운영 문항 채택

정식 평가셋 투입

수정

발문, 정답, 루브릭 보완

보류

추가 검증 전까지 사용 중지

폐기

오류, 오염, 포화 문항 제거


앵커 문항 지정

버전 간 점수 연결

```
if  $Q_i < \text{threshold}$   $\rightarrow$  revise or hold  
if  $SRI_i$  high and  $\Delta_i$  low  $\rightarrow$  anchor or retire  
if  $CDI_i$  high and  $IDQ_i$  high  $\rightarrow$  operational L3
```

11. 3층 구조: HL, EAD, AP

설계 난이도, 실제 AI 난이도, 최종 모델 성능 해석을 분리




$$P_m = (S_{\{m,L1\}}, S_{\{m,L2\}}, S_{\{m,L3\}})$$
$$S_{total} = \lambda_1 S_{L1} + \lambda_2 S_{L2} + \lambda_3 S_{L3}$$

총점은 마지막 요약값이고, 진짜 해석은 프로파일에서 나온다.

12. L1, L2, L3는 “쉬움, 보통, 어려움”보다 더 정교해야 한다

난이도 라벨은 수행 조건의 복잡도를 설명하는 기술문이어야 함




난이도 상승 = 규칙 수 증가가 아니라, 구인 상호작용과 맥락 의존성의 증가

L3 ≠ simply long text
L3 = high construct integration + high clarity + real diagnostic value

13. DDI 자동화: 인간 출제자의 에너지를 어디에 써야 하나?

인간은 문항을 만들고, 시스템은 설계난이도를 자동 산출



$$\begin{aligned} \text{DDI}_i^{\text{auto}} &= \lambda \text{DDI}_i^{\text{global}} + (1-\lambda) \text{DDI}_i^{\text{domain}} \\ \text{DDI}_i^{\text{clean}} &= \text{DDI}_i^{\text{auto}} (0.5 + 0.5Q_i) \end{aligned}$$

인간은 개별 DDI 입력자가 아니라, 기준표, 앵커 세트, 감사 규칙을 관리하는 거버넌스 주체

14. 핵심 수식은 어렵지 않다: “설계값, 실제값, 차이값”

수식은 계산 도구가 아니라 사고 정리 도구

$$DDI_i = 100 \cdot \sum_p w_p z_{ip}$$

설계난이도: 문항 구조가 얼마나 복잡한가?

$$EADI_i = 100(1 - A_i)$$

경험적 난이도: 실제 모델들이 얼마나 틀렸는가?

$$DAE_i = |DDI_i - EADI_i|$$

정렬 오차: 설계 의도와 실제 반응이 얼마나 다른가?

$$CDI_i = 0.4 \cdot DDI_i + 0.6 \cdot EADI_i$$

확정난이도: 설계 의도와 실제 반응을 결합한다.

숫자는 최종 진실이 아니라, 난이도 주장을 감사 가능하게 만드는 evidence

15. 가장 중요한 안전장치: Q_i , 문항 명료도

“어려운 문항”과 “나쁜 문항”을 구분하지 못하면 평가가 무너짐

좋은 고난도 문항

정답 근거가 명확하다

구인 복잡도가 높다

전문가 합의가 가능하다

모델 간 변별력이 있다

나쁜 문항

정답이 여러 개 가능하다

발문이 애매하다

근거가 부족하다

루브릭으로 채점하기 어렵다

모델이 틀렸다는 사실만으로 고난도라고 해석하면 안 됨

```
DDI_i^{clean} = DDI_i^{auto} (0.5 + 0.5Q_i)
Q_i \text{ low} \rightarrow \text{revise, hold, or retire}
```

16. 문항유형별 채점: 객관식만으로는 부족하다

한국어 AI 능력은 객관식, 단답형, 서술형을 함께 보되, 서술형에서는 루브릭 채점과 제약 준수를 함께 관리

객관식	단답형	서술형	(서술형 내부의) 제약 준수
정오답	허용 답안	루브릭	제약 준수
정답률, 오답 매력도, 변별도	띄어쓰기, 조사, 어미, 동의 표현 보정	언어 정확성, 추론, 근거 제시	문체, 금지어, 필수 정보, 환각 억제

$$q_{im} = w_1RB1_{im} + w_2RB2_{im} + w_3RB3_{im} + w_4RB4_{im}$$

RB1: 언어 형식 정확성, RB2: 상황 분석 및 논증 타당성, RB3: 업무 담화 수행 적절성, RB4: 과업 충족도 및 제약 준수

16-1. 적용 예시: L3 업무 메일 서술형 문항

논리 구조

공식 점수 산출 레이어: 세부 평가지표 → 문항 단위 점수 → 도메인, 난이도, 문항유형별 점수 → L1, L2, L3 점수 → 최종 종합점수
진단 레이어: 모델 응답 → 응답 구조 그래프 → 루브릭 매핑 그래프 → 감점 근거, 난이도 보정, 문항 품질관리 (재라벨링 후보 판정 포함)

1. 예시 지문

다음은 지방자치단체 산하기관의 주임 연구원이 외부 자문위원에게 보내려는 메일 초안이다.

홍길동 자문위원님, 안녕하세요.
지방연구원 연구기획팀 주임 연구원 김철수입니다.
지난번에 말씀하신 부분은 거의 고쳤고요, 예산표는 아직 저희가 못 정해서 빼놨습니다.
검토 의견 주신 내용 중 연구 목표와 추진 체계 부분은 자료에 반영했습니다.
다만 예산 산출 근거는 내부 결재가 아직 끝나지 않아서 이번 파일에는 넣지 않았습니다.
내일 오전에 중간보고 자료를 제출해야 해서 시간이 조금 촉박합니다.
확인하시고 틀린 거 있으면 오늘 안으로 알려주세요.
특히 3쪽 연구 범위와 7쪽 추진 일정 부분을 봐주시면 됩니다.
바쁘신 건 아는데, 저희도 일정이 촉박해서 빨리 봐주셔야 합니다.
확인 부탁드립니다.
김철수 드림

2. 출제 문항

다음 2개 문항에 모두 답하시오. 단, 1번은 수정 이메일 전문을 작성하고, 2번은 수정 이유를 5문장으로 설명하시오.

1. 위 메일 초안을 과잉 사과나 책임 회피 없이 상황에 맞는 공문형 업무 메일 전문으로 수정하시오.
2. 1번 문항의 수정안처럼 고친 이유를 5문장으로 설명하시오. 단, 1문장당 30자 내외로 작성하고, 총 150자 이내로 작성하시오.

3. 예시 답안

3-1. 출제 문항 1에 대한 답변: 수정 이메일 전문

홍길동 자문위원님, 안녕하세요.
지방연구원 연구기획팀 주임 연구원 김철수입니다.
지난번에 주신 검토 의견 중 연구 목표와 추진 체계 관련 내용은 자료에 반영했습니다.
다만 예산 산출 근거는 현재 내부 결재가 진행 중이므로, 확정 후 별도로 공유드리겠습니다.
내일 오전 중간보고 자료 제출 일정이 있어, 가능하시다면 금일 중 검토 의견을 부탁드립니다.
특히 3쪽 연구 범위와 7쪽 추진 일정 부분을 중심으로 검토해 주시면 감사하겠습니다.
바쁘신 가운데 검토해 주셔서 감사드립니다.
김철수 드림

3-2. 출제 문항 2에 대한 답변: 수정 이유, 5문장

1. 외부 자문위원에게 내부자처럼 압박하는 어조가 드러난다.
2. "거의 고쳤고요", "빼놨습니다"는 업무 메일 격식에 맞지 않다.
3. "틀린 거 있으면"은 자문 요청 범위를 '검토'로 완화하여 요청해야 한다.
4. "빨리 봐주셔야 합니다"는 내부 책임을 자문위원에게 전가하는 표현이다.
5. 따라서 경어법, 업무 문체, 책임 명확성이 모두 보완되어야 한다.

16-2. 적용 예시: 서술형 문항의 응답 구조 그래프와 루브릭 매핑 그래프

서술형 채점 근거, 난이도 보정, 재라벨링 후보 판정, 문항 품질관리와 대시보드 설명성을 강화하는 진단 레이어


논리 구조

공식 점수 산출 레이어 : 세부 평가지표 → 문항 단위 점수 → 도메인, 난이도, 문항유형별 점수 → L1, L2, L3 점수 → 최종 종합점수

진단 레이어 : 모델 응답 → 응답 구조 그래프 → 루브릭 매핑 그래프 → 감점 근거, 난이도 보정, 재라벨링 후보 판정, 문항 품질관리

1. 응답 구조 그래프

노드 : 상황 판단, 문제 진단, 수정 원칙, 수정안, 최종 판단. 엣지 : 추출, 지지, 위반, 도출 관계.



2. 루브릭 매핑 그래프

응답 구조 노드가 어떤 루브릭 점수의 근거인지 연결



문항 단위 점수 (예시)

$$S = (0.25 \times RB1 + 0.25 \times RB2 + 0.25 \times RB3 + 0.25 \times RB4) / 1.00$$

$$S = (0.25 \times 0.95 + 0.25 \times 0.98 + 0.25 \times 1.00 + 0.25 \times 0.95) / 1.00$$

$$S = 0.97$$

16-3. 적용 예시 해설

응답 구조와 루브릭 매핑

적용 예시의 응답 구조와 루브릭 매핑은, 모델 응답을 구조화한 뒤, 그 구조가 루브릭 점수와 어떻게 연결되는지에 대한 설명.
평가자는 단순히 "0.97점"만 보는 것이 아니라, 어떤 표현 때문에 감점 또는 가점되었는지, L3 라벨을 유지해도 되는지까지 판단할 수 있음.

예시 문항을 보고 확인해야 하는 사항

예시 문항은 외부 자문위원에게 보내는 업무 메일을 다룸. 따라서 모델은 관계 판단, 공적 문체, 완곡한 요청, 내부 책임의 명확화, 5문장 이유 설명 조건을 동시에 볼 수 있어야 함.

① 모델 응답

수정 이메일
수정 이유 5문장
원응답 로그



② Node 구조화

N0-N9 판단 흐름
문제 진단, 수정 원칙,
수정안, 최종 판단



③ Rubric 매핑

Node가 RB1-RB4
점수 근거로 연결됨



④ 운영 판단

난이도 보정
문항 품질관리
수명주기 결정

공식 점수 산출 레이어

세부 평가지표 → 문항 단위 점수 → 도메인, 난이도, 문항유
형별 점수 → L1, L2, L3 점수 → 최종 종합점수

핵심 질문: "몇 점인가?"

진단 레이어

모델 응답 → 응답 구조 그래프 → 루브릭 매핑 그래프 → 감점 근거, 난이도 보정, 문항 품질관리

핵심 질문: "왜 그 점수인가, 어떻게 운영할 것인가?"

- **응답 구조화**는 모델이 무엇을 했는지 분해하는 과정
- **루브릭 매핑**은 그것이 왜 점수 근거가 되는지 연결하는 과정

※ Node가 해결하는 문제

- ① 긴 답안을 평가 가능한 단위로 분해
- ② 루브릭 점수와 구체 근거 사이의 연결 역할
- ③ 오류 위치와 감점 원인 기록 가능
- ④ 모델 응답을 evidence 스키마 안에 저장 가능한 형태로 전환

17. 문항 단위 evidence 스키마

운영형 벤치마크는 문항마다 “작은 데이터베이스”를 가짐

식별	ID, 버전, 출처, 작성 이력	구인	도메인, 주 구인, 부 구인	난이도	DDI, EADI, DAE, IDQ, SRI, CDI	내용	지문, 발문, 선택지, 정답, 해설
채점	루브릭, 가중치, 허용 답안, 채점기	실행	모델, 프롬프트, 응답, 파라미터	로그	점수, 근거, 해시, 오 류유형	상태	후보, 파일럿, 운영, 앵커, 폐기

이 스키마가 있어야 “점수 → 해석 → 책임 있는 사용”으로 연결


18. 과학적 엄격함은 “타당화 프로그램”에서 나온다

문항을 만들었다고 끝나지 않음. 평가 도구로 검증해야 함.

- | | | |
|---|--------|-------------------------|
| 1 | 내용 타당도 | 전문가가 구인 대표성을 검토 |
| 2 | 응답 과정 | 모델이 의도된 이유로 맞았는가 |
| 3 | 내적 구조 | 도메인과 구인군이 실제 자료에서 지지되는가 |
| 4 | 외적 준거 | 기존 벤치마크, 실제 서비스 실패와 관계 |
| 5 | 신뢰도 | 문항, 프롬프트, 채점기, 모델 버전 변동 |
| 6 | 공정성 | 특정 모델군에 유리한 문항 탐지 |
| 7 | 결과 타당도 | 평가 결과가 안전한 의사결정을 돕는가 |

19. 벤치마크는 살아 있는 시스템이다

문항은 시간이 지나며 쉬워지고, 오염되고, 낡는다.




Revision triggers:

Q_i low | IDQ_i low | SRI_i high | DAE_i high | contamination risk

20. 시제품 적용: 지침서 예문 59개에서 무엇이 보였나?

이 결과는 운영형 최종 evidence가 아니라, 사전 자동 산정과 시연 로그의 예시

사전 판정 분포



주요 관찰

고어, 방언, 문체·레지스터: 난이도 사다리가 비교적 안정적

문맥 이해도, 유의어, 무형대용어: 구인 정렬성과 명료도 보완 필요

L3는 고난도성뿐 아니라 정답 유일성과 루브릭 명료성이 필수

Prototype evidence ≠ final operational evidence

Final evidence requires: independent batch run, response IDs, model builds, scoring versions

21. 한계와 위험: evidence-based가 evidence-only가 되면 위험하다

증거 기반 접근은 강하지만, 자동화된 착각을 만들 수도 있음

데이터 품질

나쁜 데이터 → 잘못된 evidence

구인 축소

측정 쉬운 것만 중요해질 위험

LLM 편향

자동 DDI가 평가자 모델의 편향을 반영

증거 노후화

모델 발전으로 문항 난이도가 빠르게 변함

가중치 정치학

무엇을 좋은 한국어 성능으로 볼지 숨겨질 수 있음

운영 복잡성

지표가 많으면 실무자가 이해하기 어려움

Evidence-based $\neq$ Evidence-only

Evidence-based = data + measurement + theory + expert judgment + governance

22. 구현 로드맵: 논문 개념을 실제 시스템으로 바꾸는 순서

처음부터 완벽한 시스템이 아니라, 단계적으로 evidence 체계를 구성

- | | | |
|---|---------------------|-------------------------|
| 1 | 문항 스키마 고정 | 도메인, 구인, 루브릭, 로그 필드 |
| 2 | 자동 DDI 엔진 | 문항 파싱, LLM 패널, Q_i 보정 |
| 3 | 파일럿 모델 실행 | 응답 원문, 채점 근거, 모델 버전 저장 |
| 4 | EADI·DAE·IDQ·CDI 산출 | 설계값과 실제값 정렬 검증 |
| 5 | 운영 대시보드 | 문항 상태, 포화, 오류유형, 감사 플래그 |
| 6 | 수명주기 거버넌스 | 앵커, 수정, 보류, 폐기, 재평가 |

최종 목표: 한국어 AI 평가를 “정적 벤치마크”가 아니라 “운영형 측정 인프라”로 구축

23. 결론: 한국어 AI 평가의 글로벌 SOTA 포지션

문항 수 경쟁이 아니라 측정 과학 인프라 경쟁

한국어 AI 평가의 혁신성

Korean items → Item-level evidence objects → Measurement infrastructure

구인 중심

문항 단위

증거 기반

계산측정학

수명주기 운영

좋은 한국어 AI 벤치마크는 문제집이 아니라, 문항별 evidence가 누적되고 갱신되는 평가 과학 시스템이다.

참고문헌 및 근거 자료

강연에서는 핵심 문헌만 제시하고, 상세 참고문헌은 논문 원고에 수록한다.

- [1] Liang et al. (2022). Holistic Evaluation of Language Models. arXiv:2211.09110.
- [2] Xiao et al. (2023). Evaluating Evaluation Metrics using Measurement Theory. EMNLP 2023.
- [3] Zhuang et al. (2023/2025). Psychometrics in AI Evaluation / AI Evaluation Should Learn from How We Test Humans.
- [4] Truong et al. (2025). Reliable and Efficient Amortized Model-Based Evaluation. arXiv:2503.13335.
- [5] Jiang et al. (2026). AI Evaluation Should Require Standardized Item-Level Data Releases. arXiv:2604.03244.
- [6] AERA, APA, NCME (2014). Standards for Educational and Psychological Testing.
- [7] Zhou et al. (2025). Lost in Benchmarks? Rethinking LLM Benchmarking with IRT.
- [8] Son et al. (2024/2025). KMMLU: Measuring Massive Multitask Language Understanding in Korean.
- [9] Lee et al. (2026). KMMMUI: Korean Massive Multi-discipline Multimodal Understanding.
- [10] 내부자료: 한국어 능력 평가 벤치마크 문항 출제 지침 v1.1, 워크숍 발표자료, 자동 난이도 산출표, GPT-5.5 시연 로그.